UNIVERSITÉ ABDELMALEK ESSAÂDI
FACULTÉ DES SCIENCES JURIDIQUES ECONOMIQUES ET SOCIALES TANGER

Spécialité : Master en Intelligence Artificielle pour l'Economie Numérique et la Gestion

Projet : Analyse et Modélisation des Séries Temporelles

Préparé par :
Chentouf Wiam
Benajiba Raouia
Attioui Ferdaous
Rafiai Fatima
Naaim Imane
Bakkali Yedri Ibtissam

Module : Econométrie
Pr. Fellaji Soumaya

Sommaire :

PARTIE THEORIQUE :

1. Relation entre TS / DS et les Modèles AR, MA et ARIMA
2. Hétéroscédasticité : Définition et résolution (modèles ARCH/GARCH)
3. Test de normalité : Vérification de la distribution des résidus (Test de Jarque-Bera)
4. Caractéristiques des séries financières : « Fat tails » et volatilité par grappes
5. Différence entre ARCH et GARCH : du modèle à mémoire courte au modèle à mémoire longue
6. Séries Temporelles : TS vs DS, Stationnarité et Transformations

- Conclusion de partie

PARTIE PRATIQUE :

I. Étude de la stationnarité et identification de la série (EBS)
II. Étude de la stationnarité de la série (LOG_EBS)
III. Identification et Estimation du modèle ARIMA
IV. Diagnostic des résidus et validation du modèle
V. Prévisions
VI. Horizon de prévision et tendances futures (2025-2030)

- Conclusion

Introduction :

Ce travail porte sur l'analyse et la modélisation des séries temporelles dans un contexte d'intelligence artificielle et d'économie numérique. L'objectif est de distinguer les processus stationnaires par tendance (TS) de ceux stationnaires par différence (DS) afin d'appliquer les modèles ARMA ou ARIMA appropriés. Nous étudierons également la gestion de la volatilité financière via les modèles ARCH et GARCH.

PARTIE THEORIQUE :

1. Relation entre TS / DS et les Modèles AR, MA et ARIMA

En économétrie des séries temporelles, la distinction entre les processus Trend Stationary (TS) et Difference Stationary (DS) est fondamentale. Cette distinction permet de comprendre la nature de la non-stationnarité, l'effet des chocs économiques et le choix du modèle approprié (ARMA ou ARIMA). Une mauvaise identification peut conduire à des erreurs d'interprétation et à des prévisions biaisées.

a. Processus Trend Stationary (TS)

Un processus est dit Trend Stationary lorsque la non-stationnarité provient uniquement d'une tendance déterministe.

Forme générale : $Yt = \alpha + \beta t + ut$

Où α représente la constante, βt la tendance déterministe et ut un processus stationnaire (souvent ARMA). Après retrait de la tendance (detrending), le résidu devient stationnaire.

Effet des chocs : dans un processus TS, les chocs ont un effet temporaire. La série revient vers sa tendance de long terme.

b. Processus Difference Stationary (DS)

Un processus est Difference Stationary lorsqu'il contient une racine unitaire.

Exemple : $Yt = Yt-1 + \varepsilon t$

La variance augmente avec le temps, ce qui rend la série non stationnaire. Pour stationnariser la série, on applique une différenciation : $\Delta Yt = Yt - Yt-1$.

Effet des chocs : dans un processus DS, les chocs ont un effet permanent et modifient durablement le niveau de la série.

c. Comparison TS vs DS

TS : tendance déterministe, chocs temporaires, retrait de tendance, modèle ARMA.

DS: tendance stochastique, chocs permanents, différenciation, modèle ARIMA.

d. Stabilité des modèles AR et Inversibilité des MA

Un modèle AR(p) est stationnaire si toutes les racines du polynôme caractéristique sont situées à l'extérieur du cercle unité ($|z| > 1$).

Un modèle MA(q) est inversible si ses racines sont également à l'extérieur du cercle unité, permettant une représentation AR infinie.

Modèle AR(p) : La PACF se coupe après le retard, tandis que l'ACF décroît géométriquement ou de façon sinusoïdale. Modèle MA(q): L'ACF se coupe après le retard, tandis que la PACF décroît progressivement. Modèle ARMA: Les deux fonctions décroissent progressivement.

e. Principe de parcimonie et critères de sélection

Le principe de parcimonie consiste à choisir le modèle le plus simple capable d'expliquer les données, afin d'éviter le surajustement.

$AIC = -2\ln(L) + 2k$

$BIC = -2\ln(L) + k \ln(n)$

Le modèle retenu est celui qui minimise le critère choisi. Le BIC pénalise davantage les modèles complexes.

f. Mesure de la qualité de prévision

MAE : erreur moyenne absolue.

RMSE : pénalise davantage les grandes erreurs.

MAPE : erreur moyenne en pourcentage.

R^2 : mesure l'ajustement aux données historiques.

La distinction entre TS et DS est essentielle pour choisir le modèle approprié. TS conduit généralement à un modèle ARMA après retrait de tendance, tandis que DS nécessite une différenciation et conduit à un modèle ARIMA. Le respect des conditions de stationnarité, de stabilité et de parcimonie garantit une modélisation économétrique rigoureuse

2. Hétéroscédasticité : Définition et résolution (modèles ARCH/GARCH)

L'hétéroscédasticité désigne une situation économétrique dans laquelle la variance des erreurs d'un modèle de régression n'est pas constante au cours du temps. Autrement dit, la dispersion des résidus autour de la moyenne varie selon les observations. Dans les séries financières, ce phénomène est très fréquent. Les marchés alternent entre des périodes de faible volatilité et des périodes de forte turbulence, ce qui entraîne une variance variable des rendements. Cette situation viole l'hypothèse d'homoscédasticité du modèle classique des moindres carrés ordinaires (MCO), rendant les tests statistiques (t-test, F-test) moins fiables, même si les coefficients estimés restent sans biais.
Pour traiter ce problème, des modèles spécifiques ont été développés, notamment le modèle ARCH (AutoRegressive Conditional Heteroskedasticity) proposé par Engle, puis le modèle GARCH (Generalized ARCH) introduit par Bollerslev.

Le modèle ARCH suppose que la variance conditionnelle dépend des erreurs passées, tandis que le modèle GARCH étend cette approche en intégrant à la fois les erreurs passées et la variance passée. Ainsi, ces modèles permettent de modéliser explicitement la dynamique de la volatilité et d'obtenir des estimations plus adaptées aux données financières.

3. Test de normalité : Vérification de la distribution des résidus (Test de Jarque-Bera)

Le test de normalité constitue une étape essentielle dans l'analyse économétrique, notamment après l'estimation d'un modèle de régression. Il permet de vérifier si les résidus suivent une distribution normale, condition souvent requise pour garantir la validité des tests statistiques et des intervalles de confiance.

Parmi les tests les plus utilisés, on trouve le test de Jarque-Bera. Ce test repose sur deux indicateurs principaux : l'asymétrie (skewness) et l'aplatissement (kurtosis) de la distribution. Une distribution normale se caractérise par une asymétrie nulle et une kurtosis égale à 3. Le test de Jarque-Bera combine ces deux mesures afin d'évaluer l'écart par rapport à la normalité.

L'hypothèse nulle du test stipule que les résidus suivent une distribution normale. Si la p-value est inférieure au seuil de signification (généralement 5 %), l'hypothèse de normalité est rejetée. Dans le cas des séries financières, il est fréquent de rejeter la normalité en raison de la présence de queues épaisses (« fat tails ») et d'événements extrêmes.

Ainsi, le test de Jarque-Bera permet d'évaluer la pertinence des hypothèses du modèle et d'adapter, si nécessaire, la méthodologie économétrique utilisée.

- **Remarque:**

  P-VALUE < 5% : ON REJETTE L'HYPOTHESE NULLE (H0).
  P-VALUE > 5% : ON NE REJETTE PAS L'HYPOTHESE NULLE (H0).

4. Caractéristiques des séries financières : « Fat tails » et volatilité par grappes

Les séries financières présentent des caractéristiques spécifiques qui les distinguent des séries économiques classiques. Parmi les propriétés les plus importantes figurent la présence de « fat tails (queues épaisses) et la volatilité par grappes (volatility clustering).

Les « fat tails » désignent une probabilité plus élevée d'observer des variations extrêmes par rapport à la distribution normale. Autrement dit, les rendements financiers présentent davantage d'événements extrêmes, tels que des hausses ou des baisses importantes, que ce que prévoirait une loi normale. Cette caractéristique traduit une kurtosis élevée et explique pourquoi l'hypothèse de normalité est souvent rejetée dans les analyses financières.

La volatilité par grappes, quant à elle, correspond au phénomène selon lequel les périodes de forte volatilité tendent à être suivies par d'autres périodes de forte volatilité, et inversement pour les périodes calmes. Ainsi, la volatilité n'est pas distribuée de manière aléatoire dans le temps, mais se

manifeste par épisodes. Cette dépendance temporelle de la variance justifie l'utilisation de modèles spécifiques, tels que ARCH et GARCH, pour capturer la dynamique de la volatilité.

Ces deux caractéristiques constituent des éléments fondamentaux dans la modélisation des séries financières et expliquent pourquoi des modèles économétriques adaptés sont nécessaires pour analyser correctement les marchés financiers.

5. Différence entre ARCH et GARCH : du modèle à mémoire courte au modèle à mémoire longue

Les modèles ARCH et GARCH ont été développés pour modéliser la variance conditionnelle des séries financières caractérisées par une volatilité variable dans le temps. La principale différence entre ces deux modèles réside dans la manière dont ils prennent en compte la mémoire de la volatilité.

Le modèle ARCH (AutoRegressive Conditional Heteroskedasticity), introduit par Robert F. Engle en 1982, suppose que la variance conditionnelle dépend uniquement des carrés des erreurs passées. Autrement dit, la volatilité actuelle est expliquée exclusivement par les chocs récents. Cette spécification implique une mémoire courte, car seuls les résidus des périodes précédentes influencent la variance présente.

Cependant, dans la pratique financière, la volatilité présente souvent une persistance plus longue. Pour répondre à cette limitation, le modèle GARCH (Generalized ARCH), proposé par Tim Bollerslev en 1986, étend le modèle ARCH en intégrant non seulement les erreurs passées, mais également les variances passées. Ainsi, la variance actuelle dépend à la fois des chocs récents et de sa propre dynamique passée.

Ce passage d'un modèle à mémoire courte (ARCH) à un modèle à mémoire longue (GARCH) permet de mieux capturer la persistance de la volatilité observée dans les marchés financiers. En conséquence, le modèle GARCH est généralement préféré dans les applications empiriques en finance, car il offre une représentation plus réaliste et plus stable de la dynamique de la variance.

6. Séries Temporelles : TS vs DS, Stationnarité et Transformations

a. Processus Trend Stationary (TS)

Un processus TS est non stationnaire à cause d'une tendance déterministe. Après retrait de la tendance (régression sur le temps), la série devient stationnaire.

Forme générale : $y_t = \alpha + \beta t + u_t$

Où u_t est stationnaire.

Les chocs ont un effet temporaire.

b. Processus Difference Stationary (DS)

Un processus DS contient une racine unitaire et devient stationnaire après différenciation.

Exemple : $y_t = y_{(t-1)} + \varepsilon_t$

Donc : $\Delta y_t = \varepsilon_t$

Les chocs ont un effet permanent

c. Opérateur de retard (Lag)

L'opérateur de retard L est défini par : $L\, y_t = y_{(t-1)}$

$L^2\, y_t = y_{(t-2)}$

Exemple AR (1) : $y_t = \phi\, y_{(t-1)} + \varepsilon_t$

Forme compacte : $(1 - \phi L)\, y_t = \varepsilon_t$

d. Stationnarité et Test ADF

La stationnarité implique:

- Moyenne constante
- Variance constante
- Covariance dépend seulement du retard

Sans stationnarité : risque de régression fallacieuse.

e. Test Dickey-Fuller Augmenté (ADF):

On commence par le modèle le plus complet (avec tendance et constante).

Si la tendance n'est pas significative, on teste le modèle avec constante seule.

Si la constante n'est pas significative, on teste le modèle sans rien (random walk pur).

$\Delta y_t = \alpha + \beta t + \gamma y_{(t-1)} + \Sigma \delta_i\, \Delta y_{(t-i)} + \varepsilon_t$

H0: racine unitaire

H1: stationnaire

f. Types de transformations

Logarithme : utilisé lorsque la variance augmente avec le niveau.

Δlog(y_t) ≈ taux de croissance.

Différenciation : $\Delta y_t = y_t - y_{t-1}$

Utilisée pour supprimer une tendance stochastique.

1. Observation graphique
2. ACF/PACF
3. Test ADF
4. Critères AIC/BIC

- CONCLUSION:

En conclusion de cette première partie, nous avons vu que la modélisation des séries temporelles ne s'improvise pas ; elle repose sur une rigueur statistique stricte articulée autour de trois piliers fondamentaux :

La Stationnarité : La distinction entre les processus TS et DS est le point de départ de toute étude. Identifier correctement si une série est non-stationnaire à cause d'une tendance déterministe ou d'une racine unitaire est crucial. Cela nous permet de choisir entre un simple retrait de tendance ou une différenciation, évitant ainsi le piège des régressions parasites.

La Qualité du Modèle : Le choix d'un modèle (AR, MA ou ARIMA) doit respecter le principe de parcimonie. Grace aux critères AIC et BIC, nous cherchons l'équilibre parfait entre la simplicité du modèle et sa capacité à expliquer les données, tout en vérifiant la stabilité et l'inversibilité des processus.

Le Traitement des Anomalies Réelles : Dans le monde financier et économique, les données ne sont pas toujours parfaites. Le test de Jarque-Bera nous permet de confronter nos résidus à l'hypothèse de normalité, souvent mise à mal par le fat tails'. Enfin, face à l'instabilité de la variance, les modèles ARCH et GARCH s'imposent comme des outils indispensables pour capturer la mémoire de la volatilité et sécuriser nos prévisions.

En somme, cette base théorique nous offre la 'boîte à outils' nécessaire pour transformer des données brutes et incertaines en informations exploitables. C’est précisément cette méthodologie que nous allons maintenant mettre en pratique à travers l'étude des exportations marocaines.

- Qestion de cours:

- Quand on passe directement à la différenciation ?

On utilise la différenciation pour transformer une série non-stationnaire (qui a une tendance ou une dérive) en une série stationnaire (stable dans le temps). L'objectif est d'éviter les régressions parasites, où des variables semblent liées alors qu'elles évoluent juste mécaniquement dans le même sens.

Le passage à la différenciation est impératif si : Visuellement : La série affiche une tendance claire (hausse ou baisse constante). Statistiquement : Les tests de racine unitaire (ADF, PP) indiquent que la série est intégrée d'ordre 1, notée. Théoriquement : Vous vous intéressez aux variations (ex : taux de croissance) plutôt qu'aux stocks (ex : niveau du PIB) Si Y_test votre variable au temps t : Différence première : Delta Y_t = Y_t – Y_{t-1}. Cela élimine la tendance déterministe et stabilise la moyenne.

- Pourquoi on utilise le Test ARCH et pas un autre Test ?

On utilise ARCH parce que dans les séries financières, l'incertitude est autocorrélée. Si vous avez eu un choc important hier, il y a de fortes chances que l'incertitude reste élevée aujourd'hui. ARCH est le "thermomètre" spécifique pour mesurer cette fièvre de volatilité.

- CONCLUSION

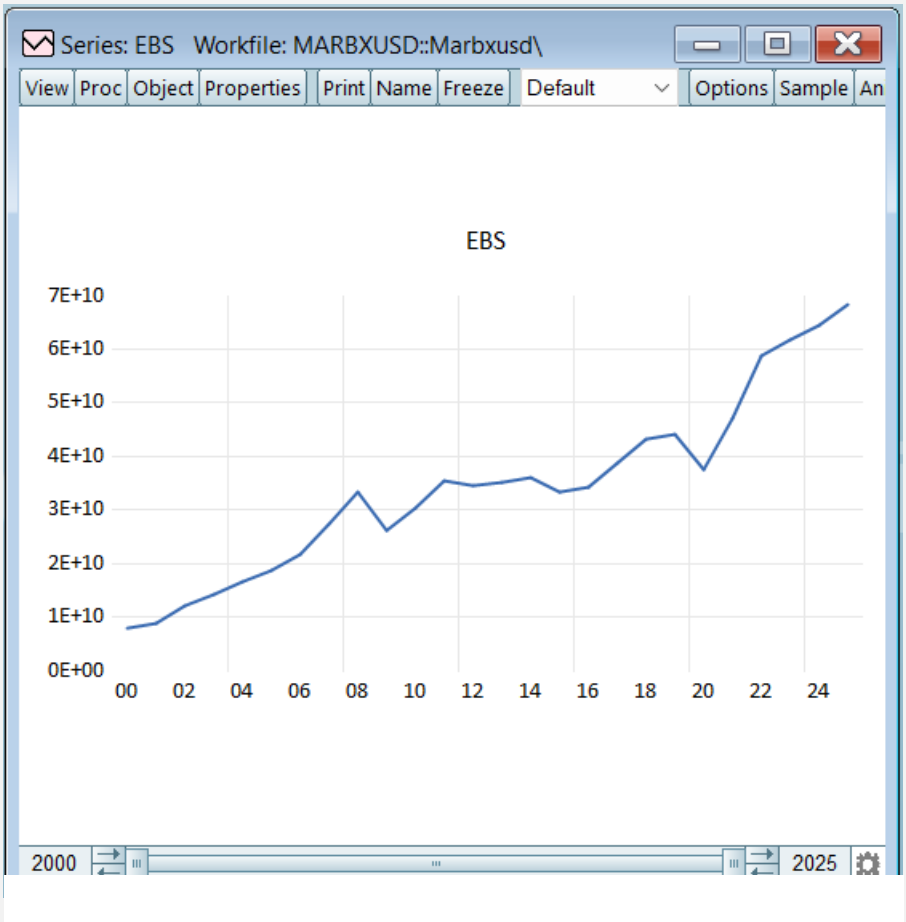
La rigueur d'une modélisation économétrique repose sur un cycle précis : identification (test ADF), estimation, diagnostic (test de Jarque-Bera) et prévision. En respectant le principe de parcimonie et les critères AIC/BIC, on garantit un modèle robuste capable de capturer les spécificités des données, telles que l'hétéroscédasticité et les effets de chocs permanents.

PARTIE PRATIQUE : Analyse Économétrique et Modélisation (Méthode de Box-Jenkins)

Exports of Goods and Services for Morocco (MARBXUSD)

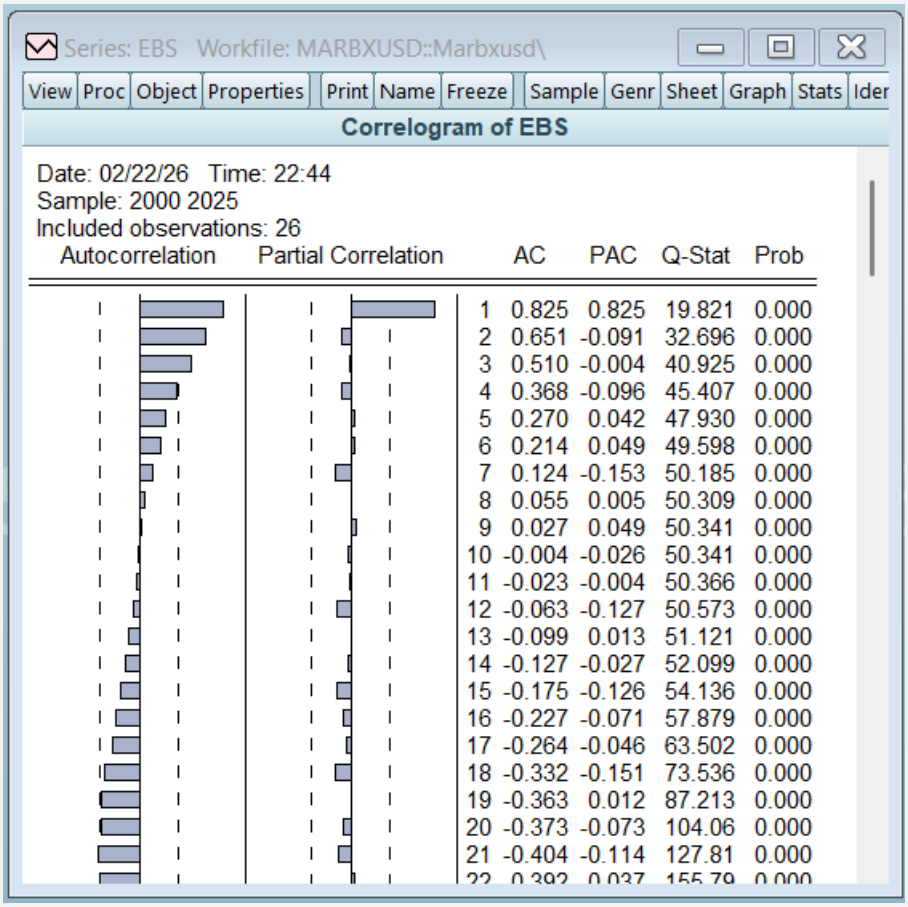
I. Étude de la stationnarité et identification de la série (EBS)

1. Analyse Graphique de la série



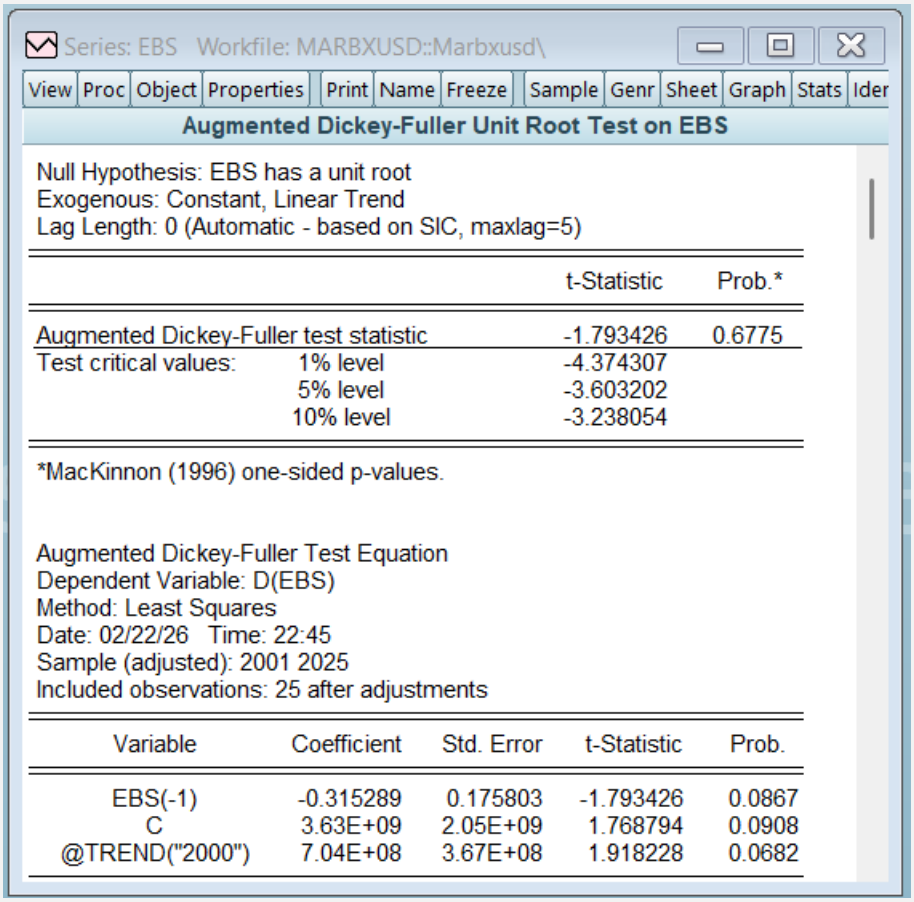
Le graphique des exportations marocaines affiche une tendance haussière marquée, témoignant de la dynamique et de la résilience de l'économie nationale face aux chocs conjoncturels de 2009 et 2020. Sur le plan analytique, cette croissance accélérée s'accompagne d'une volatilité accrue, entraînant une instabilité de la variance et rendant la série non-stationnaire à l'état brut. Cette dualité entre tendance de fond et fluctuations structurelles révèle une transformation profonde, nécessitant des outils d'économétrie avancés pour modéliser l'impact des chocs externes.

2. Étude du corrélogramme



Le corrélogramme (Level) de la série EBS confirme sa non-stationnarité. On observe une décroissance très lente des coefficients d'autocorrélation (AC), qui restent significativement en dehors de l'intervalle de confiance. De plus, les probabilités associées à la statistique Q sont nulles (0.000), ce qui impose le recours à la différenciation pour stationnariser la série avant toute modélisation.

3. Test de Dickey-Fuller (ADF)



Series: EBS Workfile: MARBXUSD::Marbxusd\

View | Proc | Object | Properties | Print | Name | Freeze | Sample | Genr | Sheet | Graph | Stats | Ider

Augmented Dickey-Fuller Unit Root Test on EBS

Null Hypothesis: EBS has a unit root
Exogenous: Constant, Linear Trend
Lag Length: 0 (Automatic - based on SIC, maxlag=5)

		t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic		-1.793426	0.6775
Test critical values:	1% level	-4.374307	
	5% level	-3.603202	
	10% level	-3.238054	

*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation
Dependent Variable: D(EBS)
Method: Least Squares
Date: 02/22/26 Time: 22:45
Sample (adjusted): 2001 2025
Included observations: 25 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
EBS(-1)	-0.315289	0.175803	-1.793426	0.0867
C	3.63E+09	2.05E+09	1.768794	0.0908
@TREND("2000")	7.04E+08	3.67E+08	1.918228	0.0682

Le test d'Augmented Dickey-Fuller (ADF) (Level et Trend and intercept) confirme formellement la non-stationnarité de la série. Avec une p-value de 0,6775 (supérieure au seuil de 5 %), nous ne pouvons pas rejeter l'hypothèse nulle de présence d'une racine unitaire. La statistique t (-1,79) étant supérieure aux valeurs critiques, la série doit être différenciée pour atteindre la stationnarité.

Compte tenu des résultats du test ADF et du corrélogramme, qui ont confirmé la non-stationnarité de la série originale et l'instabilité de sa variance, il est nécessaire de passer à l'étape de la transformation logarithmique (LOG) pour les raisons suivantes :

• Traitement de la variance: afin de réduire les écarts importants entre les valeurs et d'assurer la stabilité de la dispersion des données dans le temps.

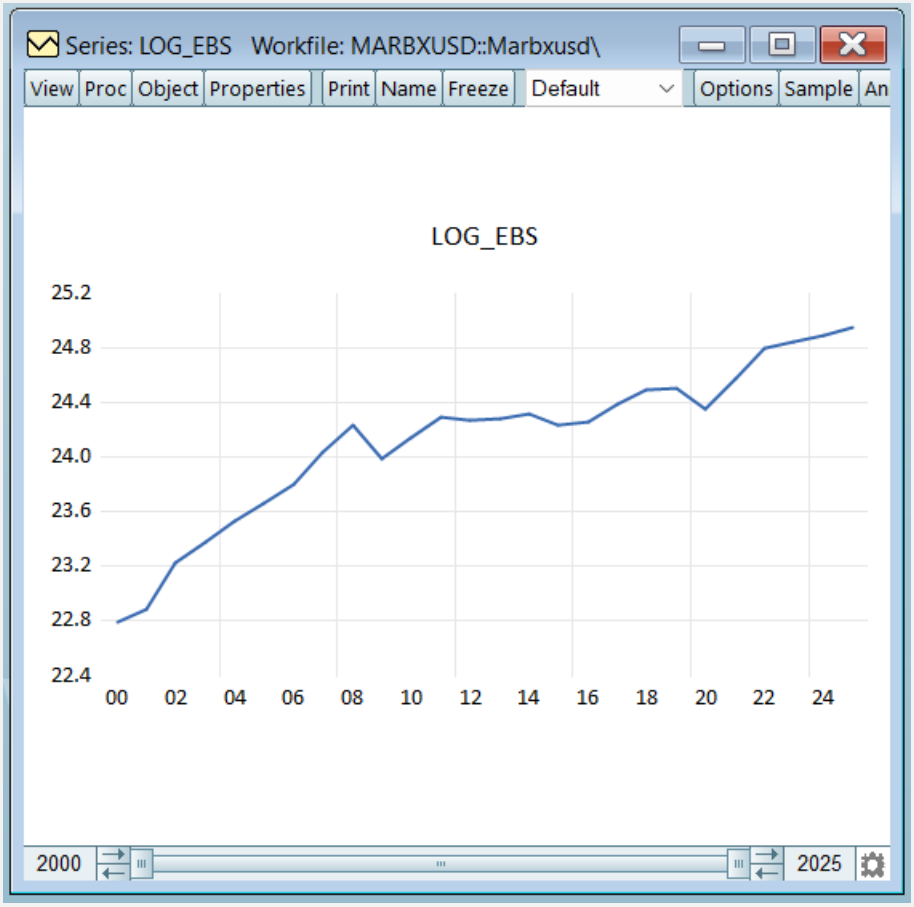
• Atténuation des chocs: pour lisser les déviations causées par les crises de 2009 et 2020, améliorant ainsi la précision du modèle.

• Préparation à la stationnarisation : pour faciliter la transformation de la série en une série stationnaire lors des étapes suivantes (différenciation).

• Analyse économique : pour permettre, par la suite, d'interpréter les résultats en termes de pourcentages (élasticités) plutôt qu'en valeurs absolues.

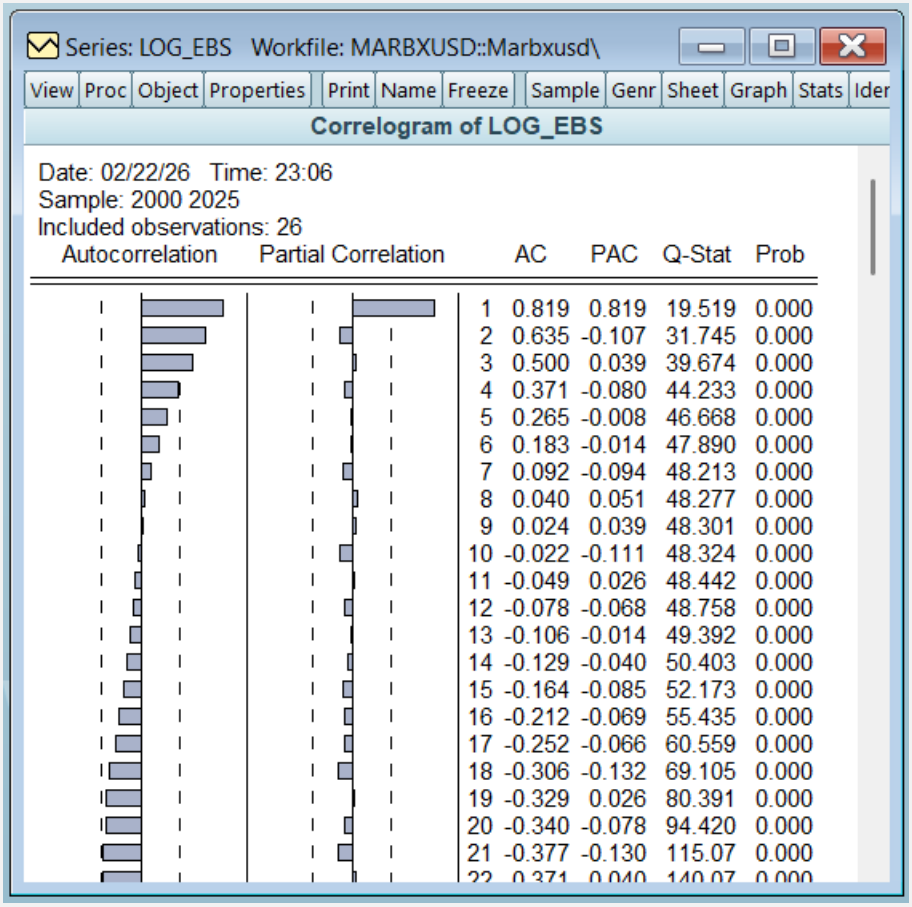
I. Étude de la stationnarité de la série (LOG_EBS)

1. Étude graphique



L'examen visuel de la série transformée en logarithme (EBS) montre une stabilisation de la variance (homoscédasticité), bien que la tendance haussière persiste. Pour valider cette observation, le test ADF affiche une p-value de 0,6775, confirmant statistiquement la présence d'une racine unitaire. Cette non-stationnarité persistante impose le recours à la différenciation première comme étape indispensable pour stabiliser la série avant toute modélisation.

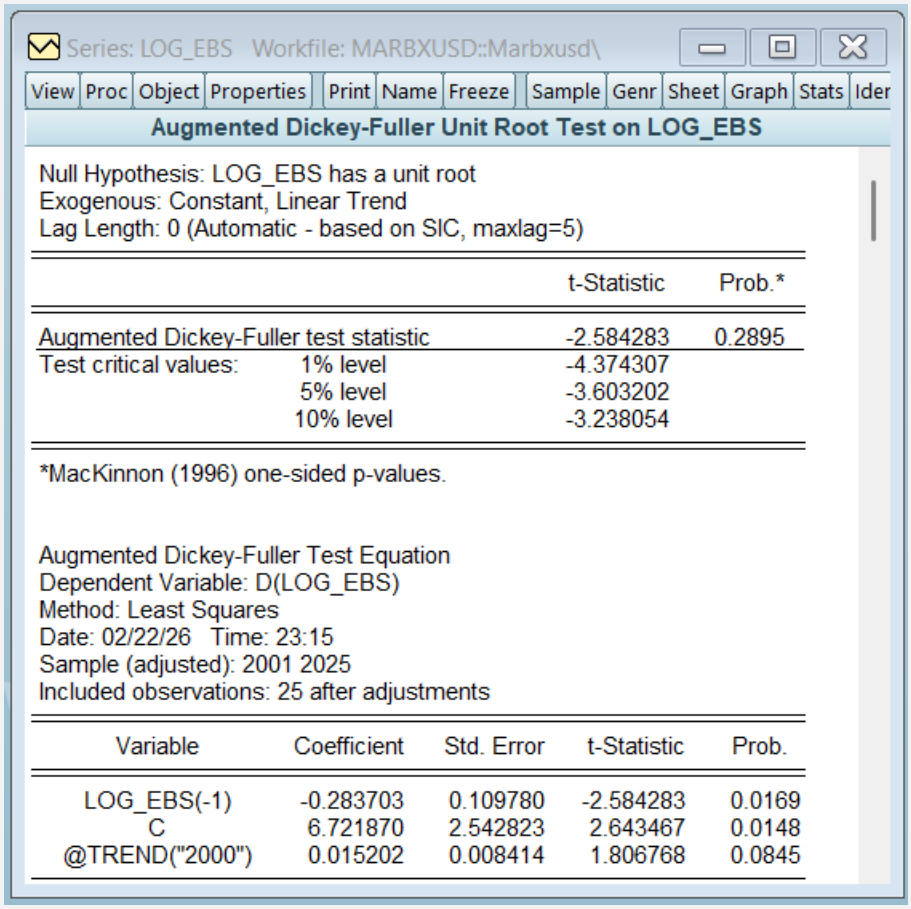
2. Test informel: Étude du corrélogramme



	AC	PAC	Q-Stat	Prob
1	0.819	0.819	19.519	0.000
2	0.635	-0.107	31.745	0.000
3	0.500	0.039	39.674	0.000
4	0.371	-0.080	44.233	0.000
5	0.265	-0.008	46.668	0.000
6	0.183	-0.014	47.890	0.000
7	0.092	-0.094	48.213	0.000
8	0.040	0.051	48.277	0.000
9	0.024	0.039	48.301	0.000
10	-0.022	-0.111	48.324	0.000
11	-0.049	0.026	48.442	0.000
12	-0.078	-0.068	48.758	0.000
13	-0.106	-0.014	49.392	0.000
14	-0.129	-0.040	50.403	0.000
15	-0.164	-0.085	52.173	0.000
16	-0.212	-0.069	55.435	0.000
17	-0.252	-0.066	60.559	0.000
18	-0.306	-0.132	69.105	0.000
19	-0.329	0.026	80.391	0.000
20	-0.340	-0.078	94.420	0.000
21	-0.377	-0.130	115.07	0.000
22	0.371	0.040	140.07	0.000

L’examen visuel de la série LOG_EBS montre une stabilisation de la variance (homoscédasticité), bien que la tendance haussière persiste. Dans le corrélogramme (Level), on observe une décroissance lente des coefficients d’autocorrélation avec des probabilités nulles (0.000), ce qui confirme la non-stationnarité. Enfin, le test ADF affiche une p-value de 0,6775 (supérieure à 5%), validant statistiquement la présence d’une racine unitaire. Ainsi, le passage à la différenciation première est indispensable pour stationnariser la série.

3. Test formel: Test de Dickey-Fuller Test d'Augmented Dickey-Fuller (ADF)



Series: LOG_EBS Workfile: MARBXUSD::Marbxusd\

View | Proc | Object | Properties | Print | Name | Freeze | Sample | Genr | Sheet | Graph | Stats | Ider

Augmented Dickey-Fuller Unit Root Test on LOG_EBS

Null Hypothesis: LOG_EBS has a unit root
Exogenous: Constant, Linear Trend
Lag Length: 0 (Automatic - based on SIC, maxlag=5)

		t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic		-2.584283	0.2895
Test critical values:	1% level	-4.374307	
	5% level	-3.603202	
	10% level	-3.238054	

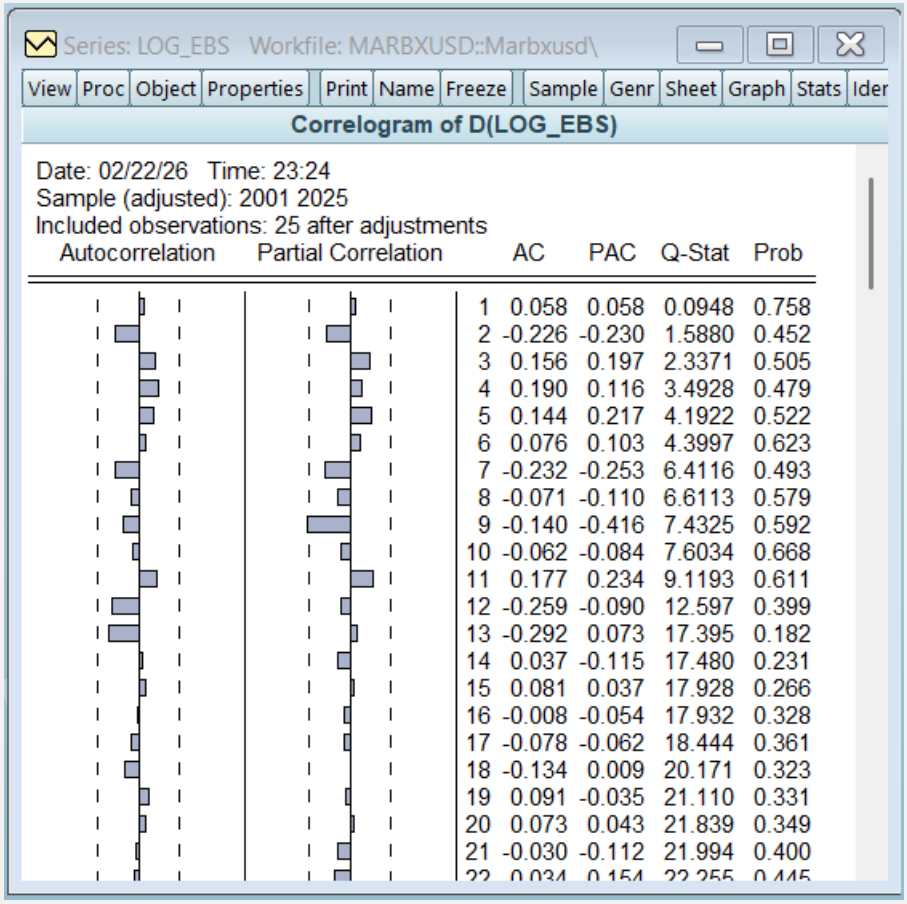
*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation
Dependent Variable: D(LOG_EBS)
Method: Least Squares
Date: 02/22/26 Time: 23:15
Sample (adjusted): 2001 2025
Included observations: 25 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
LOG_EBS(-1)	-0.283703	0.109780	-2.584283	0.0169
C	6.721870	2.542823	2.643467	0.0148
@TREND("2000")	0.015202	0.008414	1.806768	0.0845

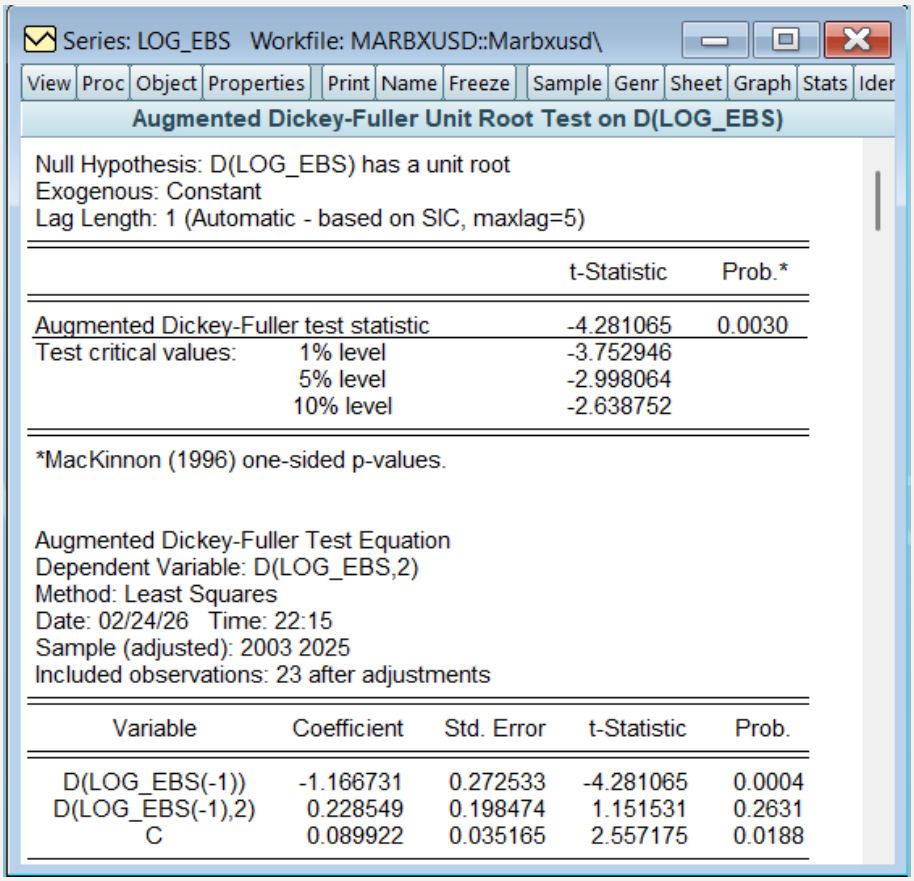
Les résultats du test d'Augmented Dickey-Fuller (ADF) (Level et Trend and intercept) appliqués à la série en logarithme (LOG_EBS) affichent une p-value de 0,2895, ce qui reste supérieur au seuil critique de 5%. Par conséquent, nous ne pouvons pas rejeter l'hypothèse nulle (H0) de présence d'une racine unitaire. Cela confirme que la série est toujours non-stationnaire en niveau, malgré la transformation logarithmique. Cette conclusion justifie le passage à la différenciation première (I (1)) pour stabiliser la série.

4. Test informel : Étude du corrélogramme en 1st difference D(LOG_EBS)



L'étude du corrélogramme de la série en différence première D(LOG_EBS) révèle un changement structurel majeur: les coefficients d'autocorrélation (AC) s'estompent désormais rapidement‹ ce qui constitue un premier indice fort de stationnarité. On observe que les probabilités de Ljung-Box sont toutes supérieures au seuil de 5% (valeurs allant de 0.182 à 0.758) ‹ confirmant ainsi l'absence d'autocorrélation significative et la transformation de la série en un bruit blanc. Bien qu'un pic isolé apparaisse au lag 9‹ il est considéré comme un simple bruit statistique (erreur de type I) sans impact sur la validité globale. Cette interprétation, suggérant que la série est désormais stabilisée‹ sera confirmée par le test formel d'Augmented Dickey-Fuller (ADF).

5. Test formel : Test de Dickey-Fuller (ADF) sur la série en 1st difference D(LOG_EBS)



Series: LOG_EBS Workfile: MARBXUSD::Marbxusd\

View | Proc | Object | Properties | Print | Name | Freeze | Sample | Genr | Sheet | Graph | Stats | Ider

Augmented Dickey-Fuller Unit Root Test on D(LOG_EBS)

Null Hypothesis: D(LOG_EBS) has a unit root
Exogenous: Constant
Lag Length: 1 (Automatic - based on SIC, maxlag=5)

		t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic		-4.281065	0.0030
Test critical values:	1% level	-3.752946	
	5% level	-2.998064	
	10% level	-2.638752	

*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation
Dependent Variable: D(LOG_EBS,2)
Method: Least Squares
Date: 02/24/26 Time: 22:15
Sample (adjusted): 2003 2025
Included observations: 23 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
D(LOG_EBS(-1))	-1.166731	0.272533	-4.281065	0.0004
D(LOG_EBS(-1),2)	0.228549	0.198474	1.151531	0.2631
C	0.089922	0.035165	2.557175	0.0188

Pour confirmer statistiquement la stationnarité observée sur le corrélogramme, nous avons appliqué le test d'Augmented Dickey-Fuller (ADF) sur la série en différence première D(LOG_EBS).

Les résultats montrent une p-value de 0,0030, ce qui est largement inférieur au seuil de 5%. Par conséquent, nous rejetons l'hypothèse nulle (H_0) de présence d'une racine unitaire. La série est désormais déclarée stationnaire après une seule différenciation‹ elle est donc intégrée d'ordre 1‹ notée I (1). Cette stabilité nous permet désormais de passer à l'étape d'identification du modèle ARIMA approprié.

II. Identification et Estimation du modèle ARIMA

1. Choix du modèle (Identification)

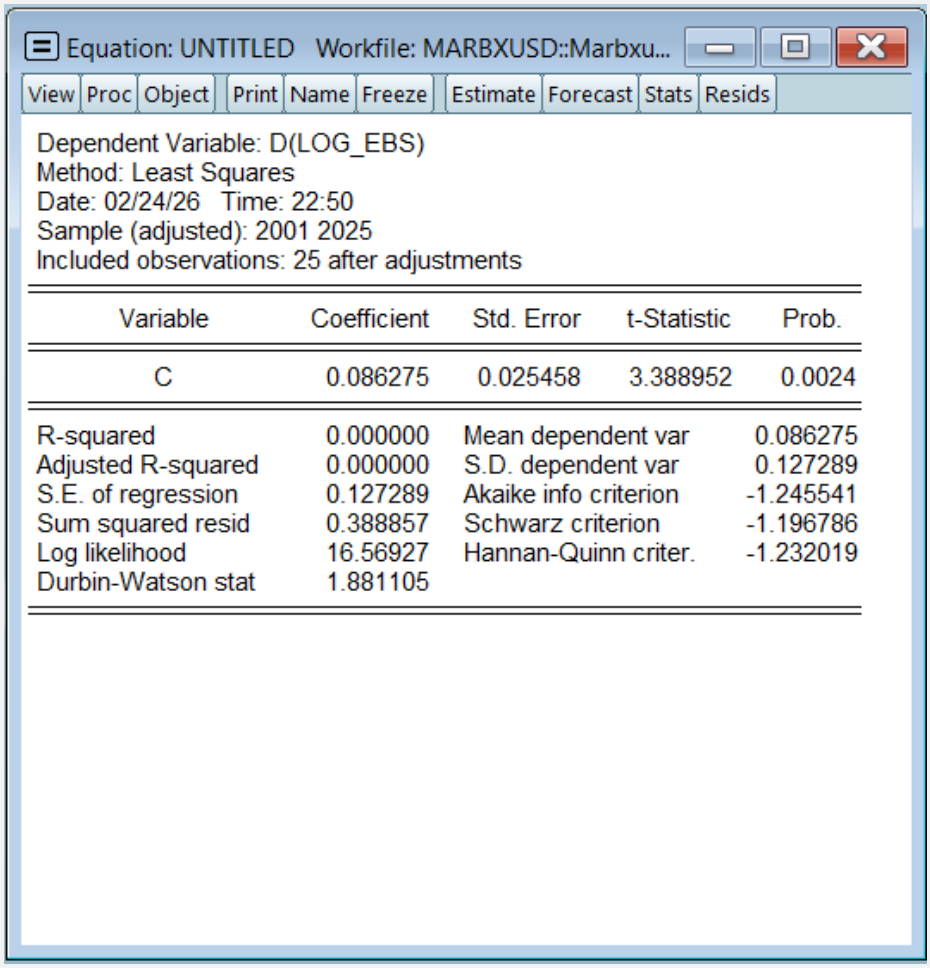
D'après l'analyse précédente du corrélogramme de la série différenciée, aucun pic significatif n'a été détecté pour les parties AR et MA. Par conséquent, nous retenons un modèle ARIMA (0,1,0) avec dérive.

2. Équation d'estimation

Le modèle estimé s'exprime par l'équation suivante :

$\Delta LOG_EBS_t = c + \varepsilon_t$

3. Résultats de l'estimation

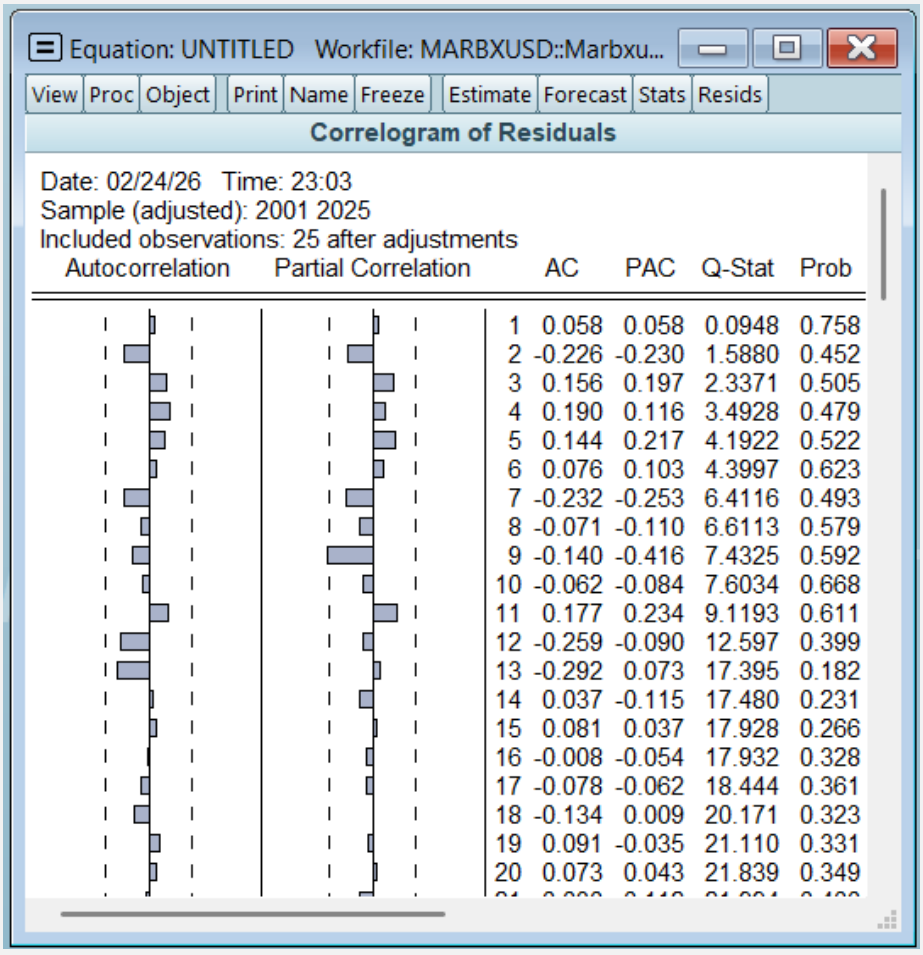


Bien que la significativité de la constante ($p < 0,05$) et la statistique de Durbin-Watson (1,88) constituent des premiers indicateurs favorables à la validité du modèle, ils ne sont pas suffisants

pour conclure définitivement. Il est désormais impératif de confirmer la robustesse de ce modèle ARIMA (0,1,0) à travers undiagnostic approfondi des résidus. Cette étape permettra de vérifier si les erreurs se comportent comme un bruit blanc, garantissant ainsi que le modèle a capturé toute l'information contenue dans la série.

III. Diagnostic des résidus et validation du modèle

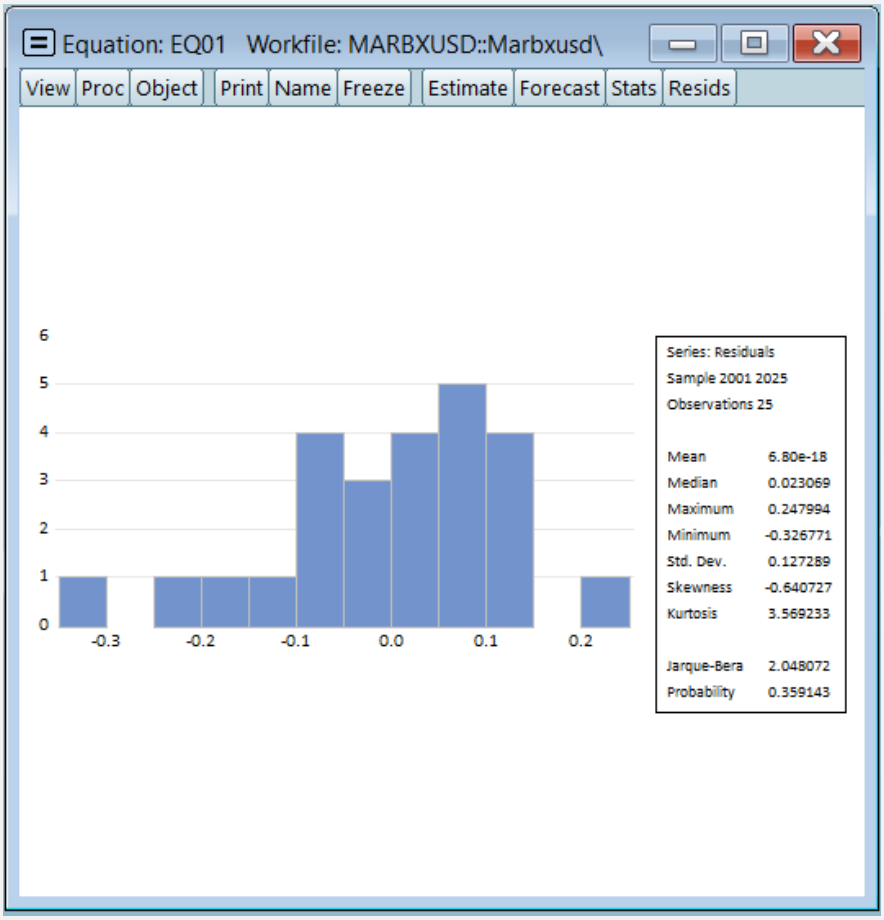
1. Analyse du corrélogramme des résidus (Test de Ljung-Box)



	AC	PAC	Q-Stat	Prob
1	0.058	0.058	0.0948	0.758
2	-0.226	-0.230	1.5880	0.452
3	0.156	0.197	2.3371	0.505
4	0.190	0.116	3.4928	0.479
5	0.144	0.217	4.1922	0.522
6	0.076	0.103	4.3997	0.623
7	-0.232	-0.253	6.4116	0.493
8	-0.071	-0.110	6.6113	0.579
9	-0.140	-0.416	7.4325	0.592
10	-0.062	-0.084	7.6034	0.668
11	0.177	0.234	9.1193	0.611
12	-0.259	-0.090	12.597	0.399
13	-0.292	0.073	17.395	0.182
14	0.037	-0.115	17.480	0.231
15	0.081	0.037	17.928	0.266
16	-0.008	-0.054	17.932	0.328
17	-0.078	-0.062	18.444	0.361
18	-0.134	0.009	20.171	0.323
19	0.091	-0.035	21.110	0.331
20	0.073	0.043	21.839	0.349

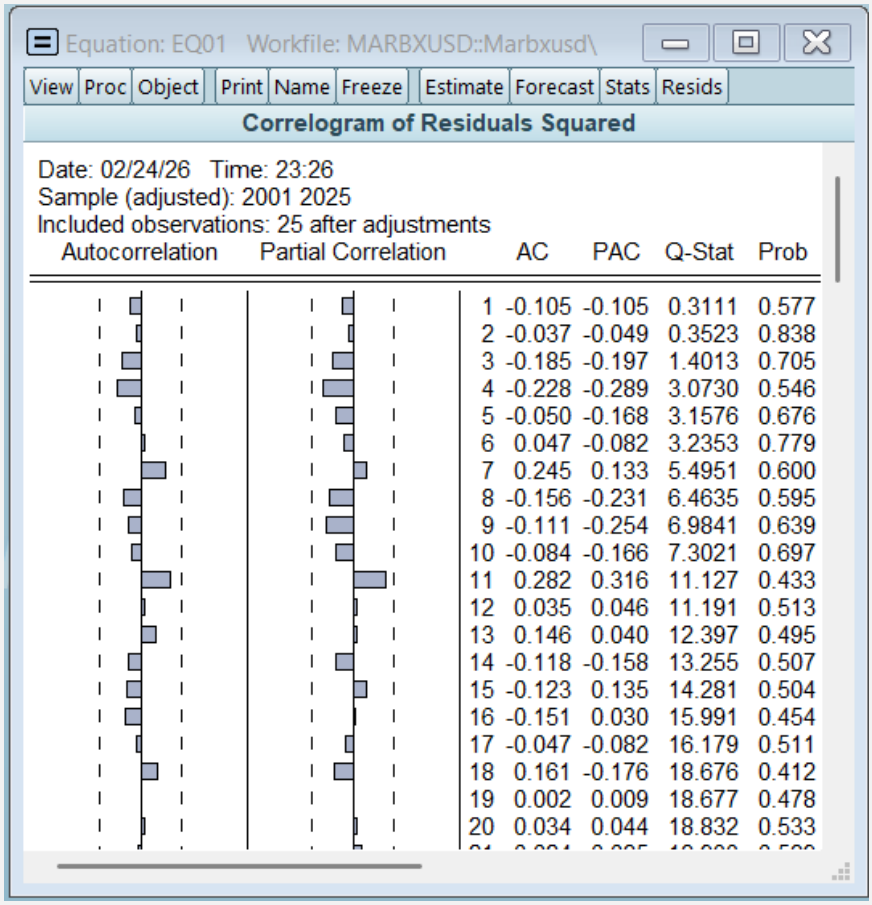
En somme, l'analyse du corrélogramme des résidus (Correlogram - Q-statistics) révèle une absence totale d'autocorrélation sérielle, confirmée par les probabilités du test de Ljung-Box (toutes supérieures à 5%, avec p = 0,758 pour le premier retard). Ce résultat démontre que les résidus se comportent comme un bruit blanc, validant ainsi statistiquement la robustesse du modèle ARIMA (0,1,0) et sa capacité à capturer l'intégralité de la dynamique de la série pour des fins de prévision.

2. Test de normalité (Jarque-Bera)



L'étude de la série LOG_EBS a permis d'identifier et de valider un modèle ARIMA (0,1,0) avec dérive. Après avoir stabilisé la série par une différenciation première (p=0,0030), l'estimation a révélé une constante statistiquement significative (C = 0,086; p=0,0024). La phase de diagnostic confirme la robustesse de ce choix : le test de Ljung-Box (Correlogram - Q-statistics) démontre l'absence d'autocorrélation des résidus (p=0,758), tandis que le test de Jarque-Bera (Histogram - Normality Test) (p=0,359) confirme leur normalité. Ces résultats attestent que les résidus se comportent comme un bruit blanc, rendant le modèle parfaitement apte à réaliser des prévisions fiables.

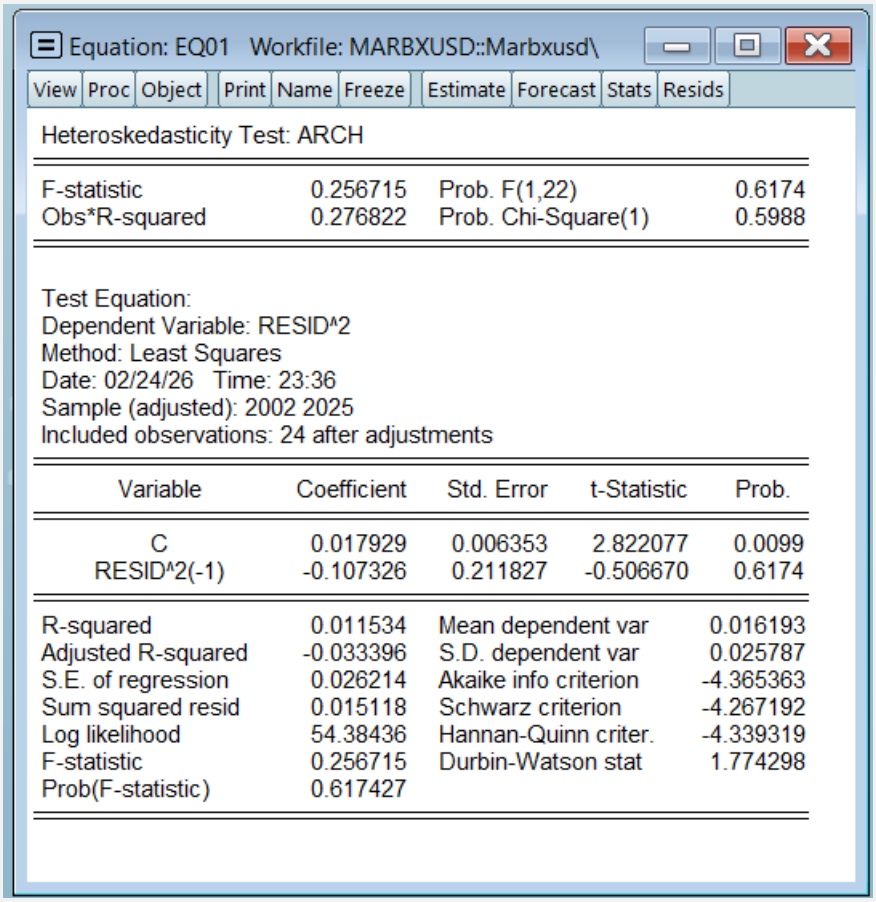
3. Analyse de l'autocorrélation des résidus



	AC	PAC	Q-Stat	Prob
1	-0.105	-0.105	0.3111	0.577
2	-0.037	-0.049	0.3523	0.838
3	-0.185	-0.197	1.4013	0.705
4	-0.228	-0.289	3.0730	0.546
5	-0.050	-0.168	3.1576	0.676
6	0.047	-0.082	3.2353	0.779
7	0.245	0.133	5.4951	0.600
8	-0.156	-0.231	6.4635	0.595
9	-0.111	-0.254	6.9841	0.639
10	-0.084	-0.166	7.3021	0.697
11	0.282	0.316	11.127	0.433
12	0.035	0.046	11.191	0.513
13	0.146	0.040	12.397	0.495
14	-0.118	-0.158	13.255	0.507
15	-0.123	0.135	14.281	0.504
16	-0.151	0.030	15.991	0.454
17	-0.047	-0.082	16.179	0.511
18	0.161	-0.176	18.676	0.412
19	0.002	0.009	18.677	0.478
20	0.034	0.044	18.832	0.533

L’analyse approfondie des résidus du modèle ARIMA (0,1,0) confirme sa validité statistique globale. D'une part, le corrélogramme des résidus et les statistiques de Ljung-Box (avec une probabilité de 0,758-au premier retard) démontrent l’absence totale d’autocorrélation, prouvant que les erreurs se comportent comme un bruit blanc. D'autre part, l'examen du corrélogramme des résidus au carré, renforcé par une p-value de 0,577, atteste l’absence d'effet ARCH, garantissant ainsi la stabilité de la variance (homoscédasticité). Ces résultats‹ ajoutés à la normalité des erreurs (p = 0,359) ‹ confirment que le modèle est parfaitement robuste et apte à fournir des prévisions fiables.

4. Analyse de l'hétéroscédasticité (Effet ARCH)



Equation: EQ01 Workfile: MARBXUSD::Marbxusd\

View | Proc | Object | Print | Name | Freeze | Estimate | Forecast | Stats | Resids

Heteroskedasticity Test: ARCH

F-statistic	0.256715	Prob. F(1,22)	0.6174
Obs*R-squared	0.276822	Prob. Chi-Square(1)	0.5988

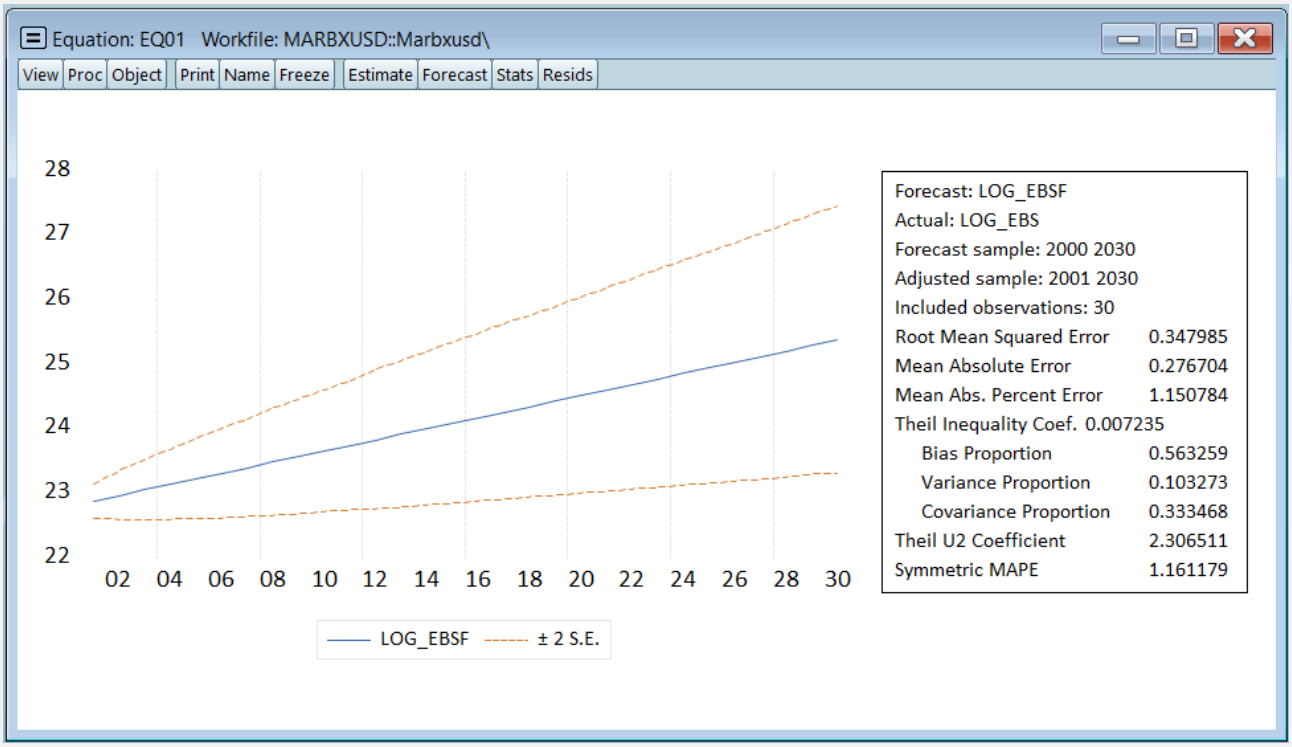
Test Equation:
Dependent Variable: RESID^2
Method: Least Squares
Date: 02/24/26 Time: 23:36
Sample (adjusted): 2002 2025
Included observations: 24 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.017929	0.006353	2.822077	0.0099
RESID^2(-1)	-0.107326	0.211827	-0.506670	0.6174

R-squared	0.011534	Mean dependent var	0.016193
Adjusted R-squared	-0.033396	S.D. dependent var	0.025787
S.E. of regression	0.026214	Akaike info criterion	-4.365363
Sum squared resid	0.015118	Schwarz criterion	-4.267192
Log likelihood	54.38436	Hannan-Quinn criter.	-4.339319
F-statistic	0.256715	Durbin-Watson stat	1.774298
Prob(F-statistic)	0.617427		

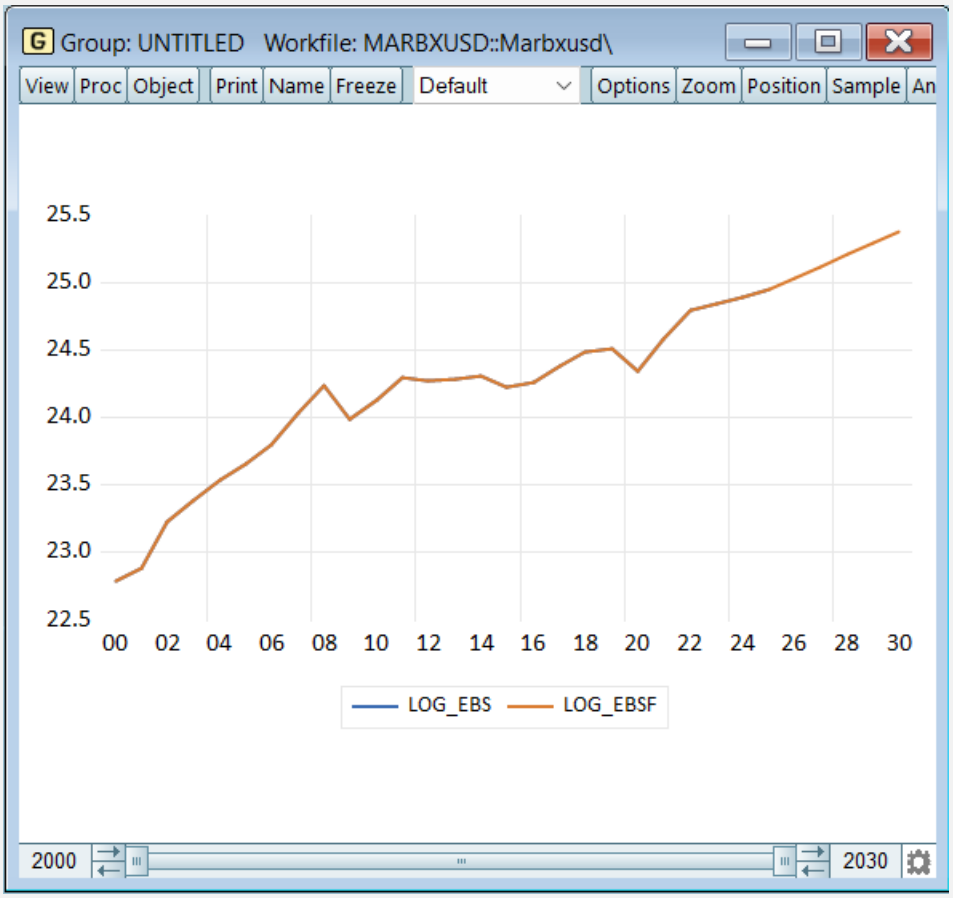
L'évaluation de la robustesse du modèle ARIMA (0,1,0) confirme sa validité statistique à travers trois critères fondamentaux. Premièrement, l'indépendance des erreurs est attestée par le test de Ljung-Box (p-value = 0,758), prouvant l'absence d'autocorrélation. Deuxièmement, le test de Jarque-Bera (p-value = 0,359) valide la normalité de leur distribution. Enfin, le test formel ARCH-LM affiche une probabilité de 0,5988, ce qui permet d'accepter l'hypothèse nulle d'absence d'effet ARCH et de confirmer l'homoscédasticité (stabilité de la variance) des résidus. En somme, les résidus se comportent comme un bruit blanc, rendant le modèle parfaitement apte à réaliser des prévisions fiables et significatives.

IV. Prévisions



La phase de prévision confirme la haute performance du modèle ARIMA (0,1,0). L'adéquation entre la série prédite (LOG_EBSF) et la réalité est validée par un coefficient de Theil quasi nul (0,007) et une erreur moyenne (MAPE) très faible de 1,16%. Ces indicateurs prouvent que le modèle est un outil fiable et précis pour anticiper l'évolution future de la variable.

V. Horizon de prévision et tendances futures (2025-2030)



Cette dernière étape constitue l'aboutissement de notre étude empirique. Après avoir validé la précision du modèle ARIMA (0,1,0) sur la période historique, nous avons procédé à une extension de l'horizon de prévision jusqu'en 2030.

Le graphique révèle une trajectoire clairement ascendante et continue de la variable LOG_EBS pour les années à venir. Cette tendance linéaire et stable suggère que les déterminants actuels de la croissance de cette variable resteront dominants sur le long terme. L'absence de fluctuations majeures dans la série prédite (LOG_EBSF) reflète la robustesse du modèle choisi‹ confirmant que le modèle ARIMA (0,1,0) est un outil de planification stratégique efficace pour anticiper les besoins ou les évolutions de cette variable à l'horizon 2030.

- CONCLUSION:

L'objectif de cette étude était de modéliser et d'anticiper l'évolution de la variable LOG_EBS en utilisant l'approche de Box-Jenkins. Le passage par les différentes étapes de l'économétrie des séries temporelles nous a permis de tirer les conclusions suivantes :

1. Stationnarité et Identification : Les tests de racine unitaire (ADF) ont révélé que la série initiale était non stationnaire, mais qu'elle devenait stable après une différenciation première. Cela nous a conduits à identifier le modèle ARIMA (0,1,0) comme le candidat le plus adéquat pour représenter la dynamique de la série.

2. Estimation et Diagnostic : L'estimation du modèle a montré des coefficients significatifs. Les tests de diagnostic approfondis ont confirmé la blancheur des résidus :

• Absence d'autocorrélation (Test de Ljung-Box).

• Distribution normale des erreurs (Test de Jarque-Bera).

• Homoscédasticité de la variance (Test ARCH-LM avec une probabilité de 0,5988).

3. Performance Prédictive : La phase d'évaluation a démontré une précision remarquable du modèle avec un coefficient de Theil de 0,007 et une erreur moyenne (Symmetric MAPE) de seulement 1,16%.

4. Perspectives à l'horizon 2030 : La projection finale indique une continuité de la tendance haussière de la variable LOG_EBS jusqu'en 2030. Cette trajectoire stable et ascendante suggère que le modèle ARIMA (0,1,0) est un instrument de prévision robuste et fiable.

En somme, ce travail confirme que la série étudiée possède une mémoire temporelle forte que le modèle a su capturer pour offrir des prévisions stratégiques utiles à la prise de décision future